

파머완 9장 추천 시스템

01. 추천시스템의 개요와 배경



- 사용자가 어떤 상품을 구매했는가?
- 사용자가 어떤 상품을 둘러보거나 장바구니에 넣었는가?
- 사용자가 평가한 영화 평점은? 제품 평가는?
- 사용자가 스스로 작성한 자신의 취향은?
- 사용자가 무엇을 클릭했는가?

➡ 데이터 기반 추천

1 추천 시스템의 유형

1. 콘텐츠 기반 필터링 (Content based filtering)
2. 협업 필터링 (Collaborativ filtering)
- a. 최근접 이웃 (Nearest Neighbor) 협업 필터링
- b. 잠재 요인 (Latent Factor) 협업 필터링
 - 넷플릭스 추천시스템 경연 대회 - 행렬분해

02. 콘텐츠 기반 필터링 추천 시스템




사용자가 매우 선호하는 특정아이템과 유사한 콘텐츠를 가진 다른 아이템 추천
키워드 유사한 다른 영화 추천



장르: SF, 드라마, 미스터리
감독: 드니 빌뇌브
출연: 에이미 아담스, 제레미 러너
키워드: 외계인 침공, 예술성, 스릴러 요소



장르: SF, 액션, 스릴러
감독: 드니 빌뇌브
출연: 라이언 고슬링, 해리스 포드
키워드: 리들리 스콧 감독의 전작을 리메이크



장르: SF, 액션, 스릴러
감독: 리들리 스콧
출연: 노미 라마스, 마이클 패스벤더
키워드: 에일리언 프리퀼, 액션과 스릴러의 조화



사용자 선호 프로파일

선호 장르: SF, 액션, 스릴러
선호 배우: 에이미 아담스, 마이클 패스벤더 등
선호 감독: 리들리 스콧, 드니 빌뇌브

03. 최근접 이웃(메모리) 협업 필터링



사용자가 아이템에 매긴 평점 정보/ 상품 구매 이력 등 사용자 행동 양식을 기반으로 추천

- **주요 목표**

➡ 축적된 데이터(ex . 사용자-아이템 평점 행렬) 기반으로 평가 **×** 아이템 예측 평가(Predicted-Rating)

- **사용행렬 - 사용자 아이템 평점 행렬**

- 행 : 개별 사용자 열: 개별 아이템
- 희소 행렬 (Sparse Matrix)

사용자가 평가하지 않은 아이템을 평가한
아이템에 기반하여 예측 평가하는 알고리즘

	Item 1	Item 2	Item 3	Item 4
User 1	3		3	✓
User 2	4	2		3
User 3		1	2	2

- 판다스의 pivot_table() 등으로 변환

로우 레벨 형태의 사용자 - 아이템 평점 데이터

User ID	Item ID	Rating
User 1	Item 1	3
User 1	Item 3	3
User 2	Item 1	4
User 2	Item 2	1
User 3	Item 4	5

➡

사용자 로우, 아이템 칼럼으로 구성된
사용자 -아이템 평점 데이터

	Item 1	Item 2	Item 3	Item 4
User 1	3		3	
User 2	4	1		
User 3				5

1 종류

- 사용자 기반 (User- User)

- 사용자와 유사 사용자가 구매한 상품 추천
- Customers like you also bought these items.
- 유사사용자를 Top-N으로 선정, 이 Top-N 사용자가 좋아하는 아이템 추천
- 유사도(Similarity) 측정 > 유사도 높은 Top-N 사용자 추출, 그 사용자들의 선호 아이템 추천
- 유사도 - 코사인 유사도 많이 적용

		다크 나이트	인터스텔라	엣지 오브 투모로우	프로메테우스	스타워즈 라스트제다이
상호간 유사도 높음	사용자 A	5	4	4		
	사용자 B	5	3	4	5	3
	사용자 C	4	3	3	2	5

사용자 A는 사용자 C보다 사용자 B와 영화 평점 측면에서 유사도가 높음. 따라서 사용자 A에게는 사용자 B가 재미있게 본 '프로메테우스'를 추천

- 아이템 기반 (item - item)  - 정확도 더 높음
 - 구매한 상품을 선택한 고객들이 구매한 상품 추천
 - customers who bought this item also bought these items.
 - 아이템의 속성과 상관 없이 사용자의 평가 척도(호오)가 유사한 아이템 추천

		다크 나이트	인터스텔라	엣지 오브 투모로우	프로메테우스	스타워즈 라스트제다이
상호간 유사도 높음	사용자 A	5	4	4		
	사용자 B	5	3	4	5	3
	사용자 C	4	3	3	2	5

사용자 A는 사용자 C보다 사용자 B와 영화 평점 측면에서 유사도가 높음. 따라서 사용자 A에게는 사용자 B가 재미있게 본 '프로메테우스'를 추천


04. 잠재 요인 협업 필터링




사용자 - 아이템 평점 매트릭스 속 잠재 요인 추출 → 추천 예측

잠재 요인 추출 - Matrix Factorization (SVD 등 차원 감소 기법으로 분해)

잠재 요인 예시 - 장르별 특성 선호도




- $R(u,i)$ - (user,item)에 대한 평점
- P - 사용자의 영화 장르별 선호도 행렬
 Q - 영화별 장르 요소 행렬
- R 의 빈칸을 $P*Q$ 내적으로 예측



1 행렬 분해의 이해


예) SVD(Singular Vector Decomposition), NMF(Non-Negative Matrix Factorization) 등

- M : 총사용자수
- N : 총 아이템 수
- K : 잠재 요인 차원수
- R : M x N 크기의 사용자 - 아이템 평점 행렬
- P : M x K의 사용자 - 잠재요인 행렬
- Q.T : K x N의 잠재요인 - 아이템 행렬
t - transpose/전치행렬 의미함




- R의 NaN 값 예측


$$R \cong \hat{R} = P * Q.T$$



- R Nan값 예측 예시



$$r_{u,i} = p_u * q_i^t$$



2 확률적 경사 하강법을 이용한 행렬 분해

확률적 경사하강법(Stochastic Gradient Descent)

- 반복적인 비용함수 최적화 → R과 $\hat{R}$ 의 실제 오차 최소화

1. P와 Q을 임의의 값을 가진 행렬로 설정

2. $P * Q.T \rightarrow R$ 계산, $R - \hat{R}$ 오류 계산
3. 이 오류값 최소화하게 P,Q를 적절한 값으로 각각 업데이트
4. 반복
 - 비용함수 식(오류 최소화, L2규제 고려)
 - p_{u*} : P 행렬의 사용자 u 행 벡터
 - q_{i*}^t : Q 행렬의 아이템 i 행 벡터의 전치 벡터
 - $r_{(u,i)}$: R 행렬의 (u,i)값
 - $\hat{r}_{(u,i)}$: $\hat{R}$ 행렬의 (u,i)값 $\rightarrow p_{u*} * q_{i*}^t$ 로 계산
 - p_{u*} : P 행렬의 사용자 u 행 벡터
 - $e_{(u,i)}$: 오차값 $\rightarrow r_{(u,i)} - \hat{r}_{(u,i)}$ 로 계산
 - η : SGD 학습률
 - λ : L2 규제(Regularization) 계수

$$\min \sum (r_{(u,i)} - p_u q_i^t)^2 + \lambda (\|q_i\|^2 + \|p_u\|^2)$$

$$\begin{aligned} \dot{p}_u &= p_u + \eta (e_{(u,i)} * q_i - \lambda * p_u) \\ \dot{q}_i &= q_i + \eta (e_{(u,i)} * p_u - \lambda * q_i) \end{aligned}$$

08. 파이썬 추천 시스템 패키지 - Surprise

Week16_예습과제_장서연.ipynb에 정리되어있음